

White Paper - Modelagem Estatística para a Copa do Mundo FIFA 2026

Previsão Probabilística via ELO, Redes Neurais Recorrentes e Simulação Monte Carlo

Gustavo José Zambrano, Maio 2026

Índice

1. [Visão Geral e Processo de Inferência Estatística](#)
 2. [O Sistema ELO como Proxy de Força Relativa](#)
 3. [Das Diferenças ELO às Taxas Esperadas de Gols](#)
 4. [Os Fatores de Correção \$K_{att}\$ e \$K_{def}\$](#)
 5. [O Modelo de Placares: Dixon-Coles sobre Poisson](#)
 6. [Simulação Monte Carlo do Torneio](#)
 7. [Resultados](#)
 8. [Conclusão](#)
 9. [Referências](#)
-

1. Visão Geral e Processo de Inferência Estatística

1.1 O Problema

Prever o vencedor de uma Copa do Mundo é essencialmente um problema de **inferência probabilística sobre um sistema estocástico com estrutura hierárquica**. O torneio é composto de dezenas de partidas interdependentes — o resultado de um jogo determina quem participa dos seguintes — e cada partida é, por si só, um evento de alta variância: equipes inferiores vencem equipes superiores com frequência não negligenciável. Modelar esse sistema corretamente exige responder a três perguntas distintas:

1. **Qual é a força relativa de cada seleção?** — pergunta de *estimação de parâmetros*
2. **Dado o par de times, qual é a distribuição de probabilidade sobre os possíveis placares?** — pergunta de *modelagem probabilística*
3. **Dada a distribuição sobre placares individuais, qual é a probabilidade de cada time vencer o torneio inteiro?** — pergunta de *propagação de incerteza* por uma estrutura combinatória complexa

O modelo desenvolvido neste trabalho responde a cada uma dessas perguntas com uma abordagem específica e fundamentada na literatura estatística.

1.2 Arquitetura Geral do Modelo

O pipeline de inferência opera em três etapas sequenciais:

Etapla 1 — Estimação da força relativa via ELO. A força de cada seleção é representada por seu rating ELO, calculado cronologicamente sobre todo o histórico de partidas internacionais desde 1872. A diferença de rating entre dois times (Δ_{eff}) serve como variável explicativa fundamental: é a partir dela que se derivam as taxas esperadas de gols (λ) via uma função exponencial quadrática cujos parâmetros são estimados por máxima verossimilhança (MLE) sobre partidas desde 1990. O ELO captura a **força estrutural e histórica** de cada seleção.

Etapla 2 — Correção pela forma recente e pelo perfil de jogo. As taxas esperadas de gols derivadas do ELO representam a expectativa de longo prazo, mas o ELO não observa o *volume* de gols — apenas o resultado final (vitória, empate, derrota). Para incorporar tanto o **desempenho ofensivo e defensivo recente** quanto o **perfil de jogo estrutural** de cada seleção, dois fatores adimensionais são estimados por time: K_{att} (multiplicador de ataque) e K_{def} (multiplicador de defesa). Esses fatores são produzidos por uma rede neural recorrente do tipo GRU ([Cho et al., 2014](#)) treinada sobre os últimos $T = 20$ jogos de cada seleção, com decaimento exponencial por posição na sequência (meia-vida de 7 jogos). A taxa final é $\lambda_A = \lambda^{home} \cdot K_{att}^A \cdot K_{def}^B$, integrando força histórica, identidade ofensiva própria e vulnerabilidade defensiva do adversário.

Etapla 3 — Distribuição de placares e propagação de incerteza. As taxas finais esperadas de gols λ_A e λ_B alimentam o modelo de [Dixon e Coles, 1997](#), que constrói uma distribuição de probabilidade conjunta sobre todos os placares possíveis (até 8 gols por time). O torneio completo é então simulado $N = 1.000.000$ de vezes via Monte Carlo, e as frequências observadas em cada fase constituem as estimativas finais de probabilidade.

O fluxo completo pode ser resumido em: `

- **Cálculo do Rating ELO** através do histórico de todas as partidas de todas as seleções.
- **Taxa esperada de gols** λ como função da diferença de rating ELO entre as duas equipes (utilizando MLE sobre todos os jogos desde 1990).
- **Correção por K_{att} e K_{def}** : forma recente e estilo de jogo calculados utilizando uma rede neural GRU treinada sobre dados recentes.
- **Distribuição de placares via Poisson modificada por Dixon-Coles.**
- **Simulação Monte Carlo: propagação de incerteza pelo torneio.** `

1.3 O Processo de Inferência Estatística em Detalhe

Formalmente, o modelo define dois conjuntos de parâmetros:

Parâmetros dos priors $\theta = \{a, b, c, h, \rho_0, \rho_1\}$: governam como a diferença ELO se traduz em taxas esperadas de gols e correlação. São estimados por **máxima verossimilhança**

(MLE) sobre partidas internacionais desde 1990, com ponderação temporal por recência (meia-vida de 4 anos) e por importância do torneio. A função de log-verossimilhança maximizada é:

$$\hat{\theta} = \arg \max_{\theta} \sum_{i=1}^{N_{hist}} w_i^{temp} \cdot \log P_{\theta}(X_i, Y_i \mid \Delta_{eff,i})$$

onde $w_i^{temp} = \exp\left(-\frac{t_{ref}-t_i}{t_{1/2}}\right)$ é o peso temporal e (X_i, Y_i) é o placar observado.

Parâmetros da rede neural ϕ : pesos da GRU que mapeiam sequências de resultados recentes em fatores K_{att} e K_{def} . São estimados por **descida de gradiente** (otimizador AdamW, $\eta = 2 \times 10^{-4}$) minimizando a log-verossimilhança negativa (NLL) Dixon-Coles ponderada, com regularização L2 sobre $\log K$:

$$\hat{\phi} = \arg \min_{\phi} \left[- \sum_i w_i \cdot \log P_{\theta, \phi}(X_i, Y_i) + \lambda_{reg} \cdot \mathbb{E}[(\log K_{att})^2 + (\log K_{def})^2] \right]$$

com $\lambda_{reg} = 0.5$ e critério de parada antecipada com paciência de 25 épocas.

A separação entre os dois conjuntos de parâmetros é deliberada: θ captura regularidades de longo prazo no futebol, enquanto ϕ captura padrões recentes por seleção. Ambos são estimados a partir dos dados, sem imposição de valores a priori além da estrutura funcional.

2. O Sistema ELO como Proxy de Força Relativa

2.1 Origem e Princípio

O sistema ELO foi proposto pelo físico húngaro-americano Arpad Elo como método de rating para xadrez ([Elo, 1978](#)). Sua ideia central é que a força de um competidor pode ser representada por um único número real, e que a diferença entre dois números codifica diretamente a probabilidade de vitória de um sobre o outro. A atualização do rating após cada partida segue a regra:

$$ELO_i^{novo} = ELO_i^{antigo} + K_w \cdot G \cdot (S_i - \hat{p}_i)$$

onde $S_i \in \{0, 0.5, 1\}$ é o resultado real (derrota, empate, vitória), $\hat{p}_i$ é a probabilidade de vitória prevista antes da partida, $K_w > 0$ é o fator de importância do torneio e G é um fator de margem de gols que amplifica o sinal de partidas com grandes diferenciais de placar:

$$G = \begin{cases} 1,0 & \text{se } |S_{home} - S_{away}| \leq 1 \\ 1,5 & \text{se } |S_{home} - S_{away}| = 2 \\ \frac{11+|S_{home}-S_{away}|}{8} & \text{caso contrário} \end{cases}$$

A probabilidade de vitória prevista é dada pela função logística:

$$\hat{p}_A = \frac{1}{1 + 10^{-\Delta_{eff}/400}}$$

onde $\Delta_{eff} = \text{ELO}_A - \text{ELO}_B + h_{fit}$

Para o modelo Dixon-Coles, o efeito do mando de jogo é $h_{fit} = 100$ pontos (estimado por MLE).

2.2 O ELO como Proxy Estatístico no Futebol

A questão de saber se o ELO é um bom proxy para a força relativa de seleções de futebol tem sido extensivamente estudada. É importante, contudo, contextualizar tanto as virtudes quanto as limitações do sistema no ambiente específico do futebol.

Em sistemas onde o ruído estocástico é nulo ou próximo de zero — como no xadrez, onde o resultado depende quase inteiramente da habilidade relativa dos jogadores — a diferença de ELO possui poder preditivo quase absoluto e imediato. No futebol, porém, a alta estocasticidade intrínseca ao esporte (gols acidentais, desvios de trajetória, decisões de arbitragem, variância nos pênaltis) faz com que o ELO opere estritamente como uma referência assintótica: ele se aproxima do "verdadeiro" nível de cada seleção apenas ao longo de muitas partidas. Esse ruído de curto prazo não pode ser eliminado pelo ELO por construção, o que torna indispensáveis as etapas posteriores do modelo — a correção pela GRU e a correção de Dixon-Coles — para mitigar esses efeitos em escala de partida individual.

[Hvattum e Arntzen \(2010\)](#) compararam o ELO com seis métodos alternativos de previsão em futebol associativo e concluíram que o sistema ELO produz previsões competitivas — e em vários cenários superiores — quando usado como covariável em modelos de regressão. A principal virtude do ELO é sua capacidade de comparar times de diferentes confederações e épocas a partir de um histórico unificado de resultados.

[Ley, Van de Wiele e Van Eetvelde \(2019\)](#) apresentaram uma comparação sistemática de dez modelos estatísticos para ranking de seleções, incluindo variantes do ELO e modelos Poisson bivariados. Os autores demonstram que modelos baseados em ELO têm desempenho preditivo comparável aos modelos estruturais mais complexos, especialmente quando combinados com ponderação temporal e por importância do torneio — exatamente as características incorporadas ao nosso pipeline.

[Gilch e Müller \(2018\)](#) aplicaram modelos de regressão Poisson com covariáveis ELO para prever a Copa do Mundo de 2018, utilizando simulação Monte Carlo para estimar probabilidades de classificação em cada fase. Esse trabalho é metodologicamente análogo ao nosso e serve como referência de validação da abordagem.

Em síntese, o ELO não é uma medida perfeita — ignora escalação, lesões e características táticas específicas — mas é um **proxy estatisticamente bem fundamentado** para a força relativa de seleções, robusto a variações de base de dados e computacionalmente eficiente.

Essas propriedades justificam seu uso como âncora do modelo, desde que complementado pelas correções descritas nas seções seguintes.

2.3 Pesos por Importância de Torneio

Nem todas as partidas têm o mesmo valor informativo. Um amistoso jogado com escalação experimental diz muito menos sobre a real capacidade de uma seleção do que uma semifinal de Copa do Mundo. Para refletir isso, cada jogo recebe um fator K_w proporcional à sua relevância competitiva, usado tanto na atualização do ELO quanto na ponderação da função de verossimilhança:

Categoria	Torneios	K_w
Copa do Mundo (FIFA)	Copa do Mundo FIFA	40
Campeonatos continentais e grandes torneios	Copa das Confederações, Eliminatórias Mundiais, Olimpíadas, etc.	35
Qualificatórias e ligas nacionais	UEFA Euro, CONCACAF Nations League, Copa América, AFC Asian Cup, etc.	30
Amistosos	-	25
Torneios não mapeados	-	28

Para a estimação dos priors por MLE, existe ainda um peso temporal adicional independente: $w_i^{temp} = \exp\left(-\frac{t_{ref}-t_i}{t_{1/2}}\right)$, com meia-vida de $t_{1/2} = 4$ anos (1.460 dias). Jogos mais antigos têm influência decrescente na calibração dos parâmetros, refletindo a evolução do futebol ao longo do tempo. O ELO, por sua vez, é calculado desde 1872 sem corte — ele "aquece" nos dados antigos — e a MLE usa apenas partidas a partir de 1990 com o ELO já estabilizado.

Para amistosos, aplica-se ainda um peso de torneio adicional de $w_{friendly} = 0.7$, multiplicado ao peso temporal. Para todos os demais torneios, $w_{torneio} = 1.0$.

2.4 Vantagem de Sede

Para a Copa 2026, os países sede — EUA, México e Canadá — jogam com uma vantagem estrutural documentada: familiaridade com o ambiente, apoio da torcida, menor desgaste de viagem e ausência de adaptação climática e de altitude. Essa vantagem é modelada como um deslocamento aditivo no delta ELO efetivo utilizado no cálculo das taxas esperadas de gols:

$$\Delta_{eff} = (\text{ELO}_A - \text{ELO}_B) + h_{fit}$$

O parâmetro h_{fit} é estimado por MLE conjuntamente com os demais priors. O valor calibrado foi $h_{fit} = 100,0$ pontos ELO, equivalente a dizer que jogar como país sede aumenta a taxa esperada de gols do time anfitrião por um fator de $e^{b \cdot h_{fit}} \approx e^{0,002 \times 100} \approx 1,22$

— ou seja, aproximadamente 22% mais gols esperados do que em campo neutro, tudo o mais constante.

3. Das Diferenças ELO às Taxas Esperadas de Gols

3.1 Por que Modelar Gols como Poisson?

A distribuição de Poisson descreve o número de ocorrências de um evento raro em um intervalo fixo de tempo ou espaço, sob a hipótese de que os eventos ocorrem a uma taxa média constante λ e de forma (aproximadamente) independente entre si. A probabilidade de observar exatamente k eventos é:

$$P(X = k \mid \lambda) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

A adequação do modelo de Poisson para gols no futebol foi estabelecida empiricamente por [Maher \(1982\)](#). Maher incorporou parâmetros de ataque e defesa por equipe e mostrou, por meio de testes de aderência (χ^2), que o modelo de Poisson independente descreve adequadamente as frequências de placares no futebol inglês, embora com pequenos desvios sistemáticos nos placares baixos — um problema que Dixon e Coles resolveriam quinze anos depois. O modelo de Poisson para gols tornou-se, desde então, o ponto de partida padrão na literatura de estatística esportiva ([Dixon e Coles, 1997](#); [Karlis e Ntzoufras, 2003](#)).

3.2 Da Diferença ELO à Taxa Esperada de Gols

Para converter Δ_{eff} em taxas esperadas de gols λ , adotamos uma função exponencial quadrática:

$$\lambda^{home}(\Delta_{eff}) = \exp(a + b \Delta_{eff} + c \Delta_{eff}^2)$$

$$\lambda^{away}(\Delta_{eff}) = \exp(a - b \Delta_{eff} + c \Delta_{eff}^2)$$

Os parâmetros $\{a, b, c\}$ são estimados conjuntamente com os demais priors por MLE. Os valores calibrados e suas interpretações são apresentados na Seção 7.1.

Interpretação do parâmetro a : O intercepto determina a taxa esperada de gols quando os dois times têm ELO idêntico ($\Delta_{eff} = 0$). Nesse caso, $\lambda = e^a$ para ambos. O valor calibrado foi $a = 0,2394$, correspondendo a $\lambda = e^{0,2394} \approx 1,270$ gols por time por jogo em campo neutro com times de igual força — coerente com a média histórica do futebol internacional de alto nível.

Interpretação do parâmetro b : O coeficiente linear captura a assimetria induzida pela diferença de qualidade. O valor calibrado foi $b = 0,002074$: para cada 100 pontos ELO de

vantagem, a taxa esperada de gols do time superior aumenta por $e^{0,002074 \times 100} \approx 1,231$ (23% mais gols esperados), enquanto a do inferior diminui simetricamente.

Interpretação do parâmetro c : O coeficiente quadrático captura a saturação para grandes diferenciais. O valor calibrado foi $c = -6,31 \times 10^{-7}$, ligeiramente negativo, indicando que o efeito marginal de cada ponto ELO adicional decresce para diferenciais muito elevados — o que é empiricamente razoável, pois não se pode marcar infinitos gols independentemente de quão superior se é.

3.3 Verificação de Consistência

Por construção, as duas funções são simétricas: inverter os papéis dos times ($\Delta_{eff} \rightarrow -\Delta_{eff}$) troca λ^{home} por λ^{away} :

$$\lambda^{home}(+\Delta) = \lambda^{away}(-\Delta)$$

Essa simetria garante que o modelo seja internamente consistente: a taxa esperada de gols de A contra B em campo de A é exatamente o que o modelo preveria para B se o jogo fosse espelhado.

3.4 O Parâmetro ρ — Correlação de Dixon-Coles

O parâmetro ρ captura a dependência estatística entre os gols das duas equipes em uma mesma partida. Sua dependência de $|\Delta_{eff}|$ é modelada por:

$$\rho(\Delta_{eff}) = \rho_{max} \cdot \tanh\left(\rho_0 - \rho_1^{neg} \cdot \frac{|\Delta_{eff}|}{400}\right)$$

com $\rho_{max} = 0,2$. Os parâmetros ρ_0 e ρ_1^{neg} são parâmetros da curva de decaimento — não confundir com o próprio ρ , que é o valor de correlação resultante para um dado Δ_{eff} . O valor de ρ_1^{neg} é forçado a ser não-negativo via $\rho_1^{neg} = \text{softplus}(\rho_1^{raw})$, garantindo que ρ seja monotonamente decrescente em $|\Delta_{eff}|$ — partidas mais desequilibradas têm menor dependência entre os gols.

Os valores calibrados foram $\rho_0^{raw} = 0,6724$ e $\rho_1^{neg} = 0,4769$, resultando em:

- $\rho(\Delta_{eff} = 0) = 0,117$ — correlação em jogo equilibrado
- $\rho(\Delta_{eff} = 400) = 0,039$ — correlação em jogo com 400 pts de diferença

Esses valores são coerentes com a estimativa original de [Dixon e Coles \(1997\)](#), que obtiveram $\rho \approx -0,13$ (com sinal oposto por diferença de convenção) para o futebol inglês.

4. Os Fatores de Correção K_{att} e K_{def}

4.1 Motivação: As Duas Limitações do ELO

O rating ELO é, por construção, uma medida de longo prazo: ele se atualiza incrementalmente a cada partida e converge lentamente para o "verdadeiro" nível de uma seleção. Isso gera duas limitações importantes quando o objetivo é modelar o volume de gols de uma partida específica.

Primeira limitação — forma recente. Um time pode ter ELO historicamente elevado mas estar em crise de resultados: mudança de treinador, lesões em jogadores-chave, período de adaptação tática. Outro pode ter ELO modesto mas estar em ascensão acelerada. O ELO não refletirá essas divergências de forma imediata.

Segunda limitação — estilo de jogo e identidade ofensiva. O ELO é cego ao *como* uma equipe vence ou perde: ele registra apenas o resultado (vitória, empate, derrota), não o placar. Dois times com ELO idêntico podem ter perfis de jogo radicalmente diferentes. Uma seleção de estilo ofensivo pode vencer por 4–2 e perder por 1–3, acumulando muitos gols nos dois lados; outra, de estilo defensivo e pragmático, pode vencer por 1–0 e empatar por 0–0, com poucos gols em ambos os sentidos. Para o ELO, os dois comportamentos são indistinguíveis. Contudo, para a modelagem de placares via Poisson, a diferença é fundamental: a taxa esperada de gols λ de cada time é muito diferente entre os dois perfis, mesmo com força igual.

Os fatores K_{att} e K_{def} corrigem ambas as limitações simultaneamente, pois são estimados a partir dos gols marcados e sofridos nos jogos recentes de cada seleção — informação que o ELO descarta completamente.

Formalmente: $K_{att} > 1$ significa que o time marca mais gols do que seu ELO preveria; $K_{att} < 1$, o contrário. $K_{def} < 1$ indica que o time sofre menos gols do que o esperado para seu nível ELO (defesa sólida ou estilo defensivo); $K_{def} > 1$, maior vulnerabilidade relativa. Ambos são adimensionais e centrados em 1: quando não há evidência de desvio, a rede retorna $K \approx 1$.

4.2 A Combinação com a Taxa Esperada de Gols

As taxas finais esperadas de gols que alimentam a distribuição de placares são:

$$\begin{aligned}\lambda_A &= \lambda^{home}(\Delta_{eff}) \cdot K_{att}^A \cdot K_{def}^B \\ \lambda_B &= \lambda^{away}(\Delta_{eff}) \cdot K_{att}^B \cdot K_{def}^A\end{aligned}$$

O número esperado de gols de A é, portanto, o produto de três componentes: o referencial do diferencial ELO, a correção pelo perfil ofensivo e forma recente do próprio time A (K_{att}^A), e a correção pela vulnerabilidade defensiva e forma recente do adversário B (K_{def}^B). O ataque de A encontra a defesa de B ; cada um entra com seu fator multiplicativo.

Se todos os fatores forem iguais a 1, $\lambda_A = \lambda^{home}$ — o modelo reduz ao prior puro, baseado apenas no diferencial ELO.

4.3 A Rede Neural GRU

Os fatores K_{att} e K_{def} são produzidos por uma **rede neural recorrente do tipo GRU** (*Gated Recurrent Unit*), introduzida por [Cho et al. \(2014\)](#) e empiricamente avaliada por [Chung et al. \(2014\)](#). A GRU processa a sequência dos últimos $T = 20$ jogos de cada seleção. Para cada jogo t da sequência, são extraídas seis variáveis ($F = 6$):

1. Diferença ELO normalizada: $\Delta_{elo}/400$
2. Gols marcados pela seleção naquele jogo (normalizados por 3)
3. Gols sofridos pela seleção naquele jogo (normalizados por 3)
4. Peso do torneio w_i (importância competitiva da partida)
5. Resultado codificado: +1 (vitória), 0 (empate), -1 (derrota)
6. Decaimento por posição: $e^{-\lambda_{decay} \cdot pos}$, com $\lambda_{decay} = \ln 2/7 \approx 0,099$ (meia-vida de 7 jogos)

Essas variáveis formam um tensor de entrada de dimensão $T \times 6$. Times com menos de T jogos são completados com zeros (*zero-padding*).

A Mecânica da GRU

A GRU mantém um vetor de estado oculto $h_t \in \mathbb{R}^H$ (com $H = 48$) atualizado a cada passo por:

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z) \quad (\text{gate de atualização})$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r) \quad (\text{gate de reset})$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h) \quad (\text{estado candidato})$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (\text{estado atualizado})$$

O **gate de atualização** z_t atua como uma *constante de inércia* do sistema: quando $z_t \approx 0$, o estado oculto é mantido essencialmente inalterado, o que equivale a dizer que o novo jogo é pouco informativo — o modelo filtra variações ruidosas do desempenho recente e não as incorpora ao perfil da seleção. Quando $z_t \approx 1$, o estado é completamente substituído pelo candidato, refletindo uma atualização decisiva na visão do modelo sobre a equipe.

O **gate de reset** r_t funciona como um *gatilho de detecção de ruptura*: quando $r_t \approx 0$, o candidato $\tilde{h}_t$ é computado ignorando quase inteiramente o histórico acumulado, permitindo que o modelo descarte o estado anterior frente a uma mudança estrutural abrupta — como uma troca súbita de comando tático ou uma série atípica de resultados que rompe com o padrão estabelecido. Combinados, os dois gates permitem à GRU distinguir entre flutuação normal de desempenho (que deve ser suavizada) e ruptura estrutural (que exige reinicialização do estado), produzindo estimativas de K_{att} e K_{def} que refletem o perfil corrente da seleção sem se deixar enganar por ruído.

O estado oculto final h_T é projetado por uma rede *feedforward* com uma camada oculta de 32 neurônios com ativação ReLU:

$$k^{raw} = W_2 \cdot \text{ReLU}(W_1 h_T + b_1) + b_2 \in \mathbb{R}^2$$

Os escalares brutos são então mapeados para os fatores K positivos pela função **softplus**:

$$K_{att} = \ln(1 + e^{k_{att}^{raw}}) + \varepsilon, \quad K_{def} = \ln(1 + e^{k_{def}^{raw}}) + \varepsilon$$

com $\varepsilon = 10^{-2}$ garantindo $K > 0$ para todo input.

4.4 Compartilhamento de Pesos e Regularização

A mesma GRU é utilizada para processar a sequência de qualquer seleção. Esse **compartilhamento de parâmetros** força o modelo a aprender uma representação universal de "forma recente" que seja interpretável da mesma forma para qualquer time, e age como regularização implícita: com 48 seleções e 20 jogos cada, o dataset é modesto, e parâmetros compartilhados reduzem o risco de sobreajuste.

A regularização explícita é feita por um termo L2 sobre $\log K$:

$$\mathcal{L}_{reg} = \lambda_{reg} \cdot \mathbb{E}[(\log K_{att})^2 + (\log K_{def})^2]$$

com $\lambda_{reg} = 0,5$. Como $\log(1) = 0$, essa regularização penaliza desvios de $K = 1$ de forma quadrática na escala logarítmica — equivalente a um prior log-normal centrado em 1. Times com histórico recente pouco informativo regridem ao referencial do ELO ($K \approx 1$).

5. O Modelo de Placares: Dixon-Coles sobre Poisson

5.1 O Problema da Independência

O modelo de Poisson independente — gols de A e B como variáveis independentes com parâmetros λ_A e λ_B — seria a escolha mais simples. Contudo, [Dixon e Coles \(1997\)](#) observaram empiricamente que esse modelo subestima sistematicamente a frequência dos placares 0-0, 1-0, 0-1 e 1-1, e superestima outros placares próximos. A causa é a dependência tática entre os times: o estado do placar influencia as escolhas de jogo de ambas as equipes, quebrando a hipótese de independência dos gols, especialmente em placares baixos.

5.2 A Correção de Dixon-Coles

Dixon e Coles propuseram uma correção multiplicativa aplicada exclusivamente aos quatro placares baixos:

$$P(X=x, Y=y) = \tau(x, y, \lambda_A, \lambda_B, \rho) \cdot \text{Pois}(x; \lambda_A) \cdot \text{Pois}(y; \lambda_B)$$

onde:

$$\tau(x, y) = \begin{cases} 1 - \lambda_A \lambda_B \rho & \text{se } x = 0, y = 0 \\ 1 + \lambda_A \rho & \text{se } x = 1, y = 0 \\ 1 + \lambda_B \rho & \text{se } x = 0, y = 1 \\ 1 - \rho & \text{se } x = 1, y = 1 \\ 1 & \text{caso contrário} \end{cases}$$

Para $\rho > 0$, os fatores τ reduzem a probabilidade dos placares 1-0 e 0-1 (fatores $1 + \lambda_A \rho > 1$ e $1 + \lambda_B \rho > 1$ atuam como denominadores da redistribuição) e aumentam relativamente o 0-0 e o 1-1. O efeito líquido, para os valores típicos de λ e ρ calibrados, é um aumento da massa probabilística nos empates de placar baixo, consistente com o padrão histórico.

Validade matemática: Para que $\tau(0, 0) = 1 - \lambda_A \lambda_B \rho > 0$, é necessário $\rho < 1/(\lambda_A \lambda_B)$. Com $\rho_{max} = 0,2$ e $\lambda \approx 1,27$, temos $1/(\lambda_A \lambda_B) \approx 0,62 \gg 0,2$, garantindo validade em todo o espaço de parâmetros utilizados. O valor $\rho = 0$ recupera o modelo de Poisson independente como caso especial.

5.3 A Distribuição sobre Resultados e Pênaltis

A partir da matriz de placares $M[x][y] = P(X = x, Y = y)$, as probabilidades de resultado são obtidas por:

$$P(\text{vitória } A) = \sum_{x > y} M[x][y], \quad P(\text{empate}) = \sum_{x=y} M[x][x], \quad P(\text{vitória } B) = \sum_{y > x} M[x][y]$$

Em partidas eliminatórias, empates levam à disputa de pênaltis. A probabilidade de vitória nos pênaltis é modelada proporcionalmente às taxas esperadas de gols:

$$P(A \text{ vence nos pênaltis}) = \frac{\lambda_A}{\lambda_A + \lambda_B}$$

5.4 A Função de Verossimilhança

O modelo é estimado por minimização da NLL ponderada:

$$\mathcal{L}_{NLL} = - \sum_{i=1}^N w_i \cdot \log P_{\theta, \phi}(X_i, Y_i)$$

onde o log da probabilidade Dixon-Coles de um placar (X, Y) é:

$$\log P(X, Y) = \log \tau(X, Y) + X \log \lambda_A - \lambda_A - \log(X!) + Y \log \lambda_B - \lambda_B - \log(Y!)$$

6. Simulação Monte Carlo do Torneio

6.1 Por que Monte Carlo?

A Copa 2026 tem 48 seleções distribuídas em 12 grupos de 4 times. Os dois primeiros colocados de cada grupo mais os 8 melhores terceiros avançam para uma fase de 32 equipes, seguida de oitavas, quartas, semifinais e final. Calcular analiticamente $P(\text{time } A \text{ vence a Copa})$ exigiria somar as probabilidades de todas as trajetórias possíveis pelo chaveamento — um espaço combinatório intratável. A simulação Monte Carlo resolve isso pela amostragem estocástica: em vez de enumerar, simula-se o torneio completo N vezes, e as frequências convergem às probabilidades verdadeiras pela Lei dos Grandes Números.

6.2 Pré-Computação das Matrizes de Placar

Para cada par ordenado de seleções (i, j) , a matriz de probabilidades de placar M_{ij} de dimensão 9×9 (placares 0–8 por time) é calculada uma única vez antes do início das simulações. Com 48 times, há $48 \times 47 = 2.256$ matrizes a pré-computar. Esse investimento inicial torna cada simulação individual muito rápida: sorteia-se apenas um inteiro de uma distribuição discreta com 81 massas pré-computadas.

6.3 O Procedimento de Simulação

Cada uma das $N = 1.000.000$ de simulações executa o torneio completo:

Fase de grupos: Para cada um dos 12 grupos, os 6 confrontos $\binom{4}{2} = 6$ são simulados sorteando um placar da distribuição M_{ij} . A classificação final é determinada pela seguinte hierarquia:

1. Pontos totais (3 por vitória, 1 por empate)
2. Confronto direto (pontos, saldo e gols no(s) jogo(s) direto(s))
3. Saldo de gols geral
4. Gols marcados no total
5. Sorteio (em caso de empate absoluto)

Melhores terceiros: Os 12 terceiros colocados são ordenados por pontos, saldo de gols e gols marcados. Os 8 melhores avançam, completando os 32 classificados.

Fase eliminatória: Em cada confronto, sorteia-se um placar de M_{ij} . Em caso de empate, decide-se nos pênaltis por uma Bernoulli com $p = \lambda_A / (\lambda_A + \lambda_B)$.

6.4 Estimativa das Probabilidades e Intervalos de Confiança

Após $N = 1.000.000$ de simulações, a estimativa da probabilidade de cada time atingir uma fase f é:

$$\hat{p}_{i,f} = \frac{\text{número de simulações em que o time } i \text{ atingiu a fase } f}{N}$$

O intervalo de confiança binomial de 95% é:

$$IC_{95\%} = \hat{p}_{i,f} \pm 1,96 \cdot \sqrt{\frac{\hat{p}_{i,f}(1 - \hat{p}_{i,f})}{N}}$$

Com $N = 1.000.000$, a margem de erro máxima (95é $\pm 0,098\%$.

7. Resultados

7.1 Parâmetros do Modelo Calibrado

A tabela abaixo apresenta os seis parâmetros dos priors estimados por MLE, juntamente com sua interpretação e os valores derivados mais relevantes.

Parâmetro	Valor	Interpretação
a	0,2394	$\lambda = e^a = 1,270$ gols esperados por time em campo neutro com times iguais
b	0,002074	Sensibilidade linear: +100 pts ELO $\Rightarrow$ +23% gols esperados
c	$-6,31 \times 10^{-7}$	Curvatura quadrática (saturação para grandes diferenciais)
h_{fit}	100 pts ELO	Vantagem de sede equivalente em pontos ELO
ρ_0^{raw}	0,6724	$\rho(\Delta = 0) = 0,117$ (correlação em jogo equilibrado)
ρ_1^{neg}	0,4769	Decaimento: $\rho(\Delta = 400) = 0,039$

O painel de diagnóstico do modelo de priors é apresentado na figura abaixo:



O painel contém doze sub-gráficos: (i) a curva $\lambda \times \Delta \text{ELO}$, mostrando a relação exponencial simétrica entre diferencial e taxa esperada de gols; (ii) gols observados vs. modelados por bin de ΔELO , confirmando boa aderência; (iii) taxa de vitória do mandante por diferencial, com e sem vantagem de sede; (iv–vi) distribuições de placar observadas, modeladas e resíduos; (vii) distribuição total de gols por jogo; (viii) a curva $p(|\Delta \text{ELO}|)$; (ix) calibração de

vitórias previstas vs. observadas; (x) pesos temporais; (xi) gols esperados em confrontos típicos; (xii) tabela de parâmetros fitados.

7.2 ELO e Fatores K por Seleção

A tabela abaixo apresenta, para cada seleção participante da Copa 2026, o rating ELO pré-torneio, os fatores K_{att} e K_{def} estimados pela GRU e o grupo de origem. As seleções estão ordenadas por ELO decrescente.

#	Seleção	Gr	Sede	ELO	K_{att}	K_{def}
1	Espanha	H		2182	0,9598	1,0897
2	Argentina	J		2169	0,9626	1,0120
3	França	I		2120	0,9634	1,0338
4	Brasil	C		2061	0,9773	0,9607
5	Inglaterra	L		2045	0,9554	0,9755
6	Colômbia	K		2042	1,0070	0,9672
7	Portugal	K		2025	0,9861	0,9831
8	Holanda	F		2010	0,9863	1,0112
9	Equador	E		1999	0,9001	0,8951
10	Alemanha	E		1985	1,0084	1,0281
11	Japão	F		1983	0,9566	0,9683
12	Croácia	L		1981	0,9696	1,0125
13	Marrocos	C		1968	0,8865	0,9876
14	Uruguai	H		1961	0,9248	0,9291
15	Suíça	B		1944	1,0140	1,0088
16	Bélgica	G		1944	1,0133	0,9968
17	Noruega	I		1932	1,0454	1,0505
18	Turquia	D		1928	0,9629	1,0212
19	México	A	✓	1927	0,9580	0,9360
20	Senegal	I		1922	0,9626	0,9840
21	Paraguai	D		1893	0,9604	0,9399
22	Áustria	J		1888	0,9704	0,9822
23	Austrália	D		1886	0,9659	0,9670
24	Canadá	B	✓	1884	0,9474	0,9273
25	Irã	G		1880	0,9669	0,9610
26	Coreia do Sul	A		1861	0,9664	0,9854
27	Argélia	J		1861	0,9643	0,9846

#	Seleção	Gr	Sede	ELO	K_{att}	K_{def}
28	Panamá	L		1822	0,9573	0,9954
29	Uzbequistão	K		1817	0,9286	0,9393
30	EUA	D	✓	1809	1,0980	1,0510
31	Costa do Marfim	E		1798	0,9496	0,9357
32	Egito	G		1791	0,9102	0,9484
33	Escócia	C		1791	0,9927	0,9502
34	Suécia	F		1783	1,0876	1,0779
35	Rep. Tcheca	A		1782	0,9809	0,9980
36	Tunísia	F		1763	0,9623	0,9526
37	Jordânia	J		1763	1,0615	1,0077
38	DR Congo	K		1750	0,9123	0,9559
39	Nova Zelândia	G		1730	1,1262	0,9742
40	Iraque	I		1723	0,9046	0,9792
41	Haiti	C		1676	1,0296	0,9933
42	Arábia Saudita	H		1670	0,9797	0,9607
43	Cabo Verde	H		1662	0,9560	0,9648
44	Bósnia-Herz.	B		1651	0,9969	0,9442
45	África do Sul	A		1645	0,9919	0,9906
46	Gana	L		1626	1,0234	0,9977
47	Curaçao	E		1586	1,0269	1,0280
48	Catar	B		1553	1,0263	1,0561


Leituras notáveis da tabela:

- **Espanha e Argentina** lideram o ELO com vantagem clara sobre o campo. A Espanha apresenta $K_{def} = 1,090$, indicando que seu estilo de posse e pressão alta gera mais gols sofridos do que o esperado para uma equipe de seu nível — o ELO puro subestimaria sua vulnerabilidade defensiva. A Argentina tem $K_{def} = 1,012$, próximo ao neutro.
- **Colômbia** ($K_{att} = 1,007$, $K_{def} = 0,967$) e **Brasil** ($K_{def} = 0,961$) apresentam perfis defensivos sólidos, marcando menos e sofrendo menos do que o ELO preveria.
- **EUA** ($K_{att} = 1,098$, $K_{def} = 1,051$) têm perfil de alta intensidade em ambos os sentidos, com os dois fatores acima de 1 — combinação que, em campo próprio com a vantagem de sede, produz jogos de alto volume de gols.
- **Marrocos** ($K_{att} = 0,887$) e **Equador** ($K_{att} = 0,900$) têm os menores multiplicadores de ataque entre os times de ELO mais alto, indicando estilo mais cauteloso ofensivamente.

- **Nova Zelândia** ($K_{att} = 1,126$) tem o maior multiplicador de ataque entre todas as seleções, mas com ELO baixo (1.730), o efeito na taxa esperada de gols final é limitado.


7.3 Probabilidades de Título e Progressão por Fase

O gráfico abaixo apresenta as probabilidades de título para as 32 seleções mais favoritas, derivadas de 1.000.000 de simulações Monte Carlo:



O heatmap a seguir mostra as probabilidades de avançar a cada fase para todas as 48 seleções:

Heatmap: Probabilidade de Avançar para cada Fase (%)



8. Conclusão

A equação central que resume o modelo é:

$$\lambda_A = \underbrace{\exp(a + b \Delta_{eff} + c \Delta_{eff}^2)}_{\text{força histórica (ELO)}} \cdot \underbrace{K_{att}^A}_{\text{ataque recente} \\ + \text{perfil ofensivo}} \cdot \underbrace{K_{def}^B}_{\text{defesa do adversário} \\ + \text{perfil defensivo}}$$

Este trabalho apresenta um modelo probabilístico para previsão de resultados na Copa do Mundo FIFA 2026, combinando três componentes que se complementam de forma coerente.

O **sistema ELO** fornece a base estrutural. A diferença de rating entre dois times, calculada cronologicamente sobre décadas de futebol internacional, é convertida em taxas esperadas de gols por uma função exponencial quadrática estimada por MLE sobre partidas desde 1990. Os parâmetros calibrados ($a = 0,239$, $b = 0,00207$, $c = -6,3 \times 10^{-7}$) são estatisticamente fundamentados e interpretáveis: a taxa esperada de 1,27 gols por time por jogo em campo neutro, o efeito de +23% de gols para cada 100 pontos ELO de vantagem e a vantagem de sede de 100 pontos ELO equivalente são todos consistentes com a literatura empírica.

Os **fatores** K_{att} e K_{def} , estimados por uma rede neural GRU sobre os 20 jogos mais recentes de cada seleção, corrigem as duas limitações estruturais do ELO na modelagem de placares: a lentidão de adaptação à forma recente e a cegueira ao volume de gols. Os valores estimados revelam perfis de jogo distintos e empiricamente plausíveis: Espanha com defesa mais exposta do que seu ELO sugere ($K_{def} = 1,09$), Brasil com defesa compacta ($K_{def} = 0,96$), EUA com estilo de alta intensidade em ambos os sentidos, Marrocos e Equador com identidade ofensiva abaixo do ELO.

O **modelo de Dixon-Coles** traduz as taxas esperadas de gols λ em distribuições de probabilidade sobre placares, corrigindo o viés da dupla-Poisson independente nos placares baixos. A **simulação Monte Carlo** com $N = 1.000.000$ de iterações propaga essa distribuição por toda a estrutura do torneio com margem de erro inferior a $\pm 0,1\%$.

O resultado central das simulações é a concentração de probabilidade entre Espanha e Argentina, cada uma com aproximadamente 20% de chance de título — reflexo de sua superioridade clara em ELO sobre o restante do campo. A França é a terceira favorita com 11,6%, seguida por Brasil (6,7%) e Colômbia (6,0%).

9. Referências

- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). *Learning Phrase Representations using RNN Encoder-Decoder*

for Statistical Machine Translation. Proceedings of EMNLP 2014. [arXiv:1406.1078](#)

- **Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014).** *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*. [arXiv:1412.3555](#)
- **Dixon, M. J., & Coles, S. G. (1997).** *Modelling Association Football Scores and Inefficiencies in the Football Betting Market*. Journal of the Royal Statistical Society: Series C (Applied Statistics), 46(2), 265–280. [doi:10.1111/1467-9876.00065](#)
- **Elo, A. E. (1978).** *The Rating of Chessplayers, Past and Present*. Arco Publishing, New York.
- **Gilch, L. A., & Müller, S. (2018).** *On Elo Based Prediction Models for the FIFA Worldcup 2018*. [arXiv:1806.01930](#)
- **Groll, A., Schauburger, G., & Tutz, G. (2015).** *Prediction of Major International Soccer Tournaments Based on Team-Specific Regularized Poisson Regression*. Ludwig-Maximilians-Universität München. [Link](#)
- **Hvattum, L. M., & Arntzen, H. (2010).** *Using ELO Ratings for Match Result Prediction in Association Football*. International Journal of Forecasting, 26(3), 460–470. [doi:10.1016/j.ijforecast.2009.10.002](#)
- **Karlis, D., & Ntzoufras, I. (2003).** *Analysis of Sports Data by Using Bivariate Poisson Models*. Journal of the Royal Statistical Society: Series D (The Statistician), 52(3), 381–393. [doi:10.1111/1467-9884.00366](#)
- **Ley, C., Van de Wiele, T., & Van Eetvelde, H. (2019).** *Ranking Soccer Teams on the Basis of Their Current Strength: A Comparison of Maximum Likelihood Approaches*. Statistical Modelling, 19(1), 55–73. [doi:10.1177/1471082X18817650](#)
- **Maher, M. J. (1982).** *Modelling Association Football Scores*. Statistica Neerlandica, 36(3), 109–118. [doi:10.1111/j.1467-9574.1982.tb00782.x](#)
- **McHale, I., & Scarf, P. (2011).** *Modelling the Dependence of Goals Scored by Opposing Teams in International Soccer Matches*. Statistical Modelling, 11(3), 219–236. [doi:10.1177/1471082X1001100204](#)